金融投研智能体 • 项目计划书

2026 北京市大学生金融人工智能竞赛。参赛方向：数据结构化提取、上市公司财务报告分析、研究报告纠错核查。版本日期：2026-10-18。

项目摘要

金融投研工作的难点不只是找到一段文字，而是把材料中的数字、期间、单位和口径绑定到可复核的证据，再在该证据范围内完成计算、推理和报告。通用大模型能够理解自然语言，却容易在财务数字、页码引用和比较口径上产生看似合理但无法验证的结论。

本项目构建一个面向金融材料核查的智能体系统。系统从公告、年度报告、半年度报告和季度报告中提取带页码与文件指纹的字段，使用大语言模型拆解研究报告草稿并请求受限工具，再由本地 Python 与 Decimal 完成数值复算、期间门控和最终裁决。输出包括结构化 JSON、指标表、核查报告、原文页图、修改片段、执行轨迹和完整复现包。

系统的核心不是生成更多文字，而是让每条结论能够回答三个问题：依据来自哪里，数字怎样计算，过程能否复现。

业务场景与问题

金融研究员通常需要在短时间内完成材料整理、财务数据提取、比较口径确认、研报复核和报告撰写。人工流程存在四类高频风险：

1. 数字与期间错绑。金额中的四位数字可能被误认为年份，累计值可能被误作单季值，上年末余额可能被误作同比基期。

2. 单位与口径混淆。同一指标可能使用元、千元或百万元；营业收入与营业总收入可能不是同一口径；历史数据可能包含追溯重述。

3. 证据与结论脱节。报告中出现一个数值，但没有说明来自哪份文件、哪一页、哪个字段以及采用什么计算规则。

4. 模型越权判断。大模型可能直接给出投资结论，或把低质量抽取、缺失证据和未知口径当成确定事实。

本项目将这些风险转化为工程门控：无法唯一定位时不猜公司，缺少可比依据时不计算，证据不足时输出补证要求，程序失败时保留部分结果并标明未完成状态。

设计目标与原则

- 可核验：结论绑定文件 SHA、PDF 页序、印刷页码、字段原文和坐标。
- 可追溯：记录文件访问、抽取通道、工具调用、公式、操作数、门控和模型返回。
- 可复现：归档运行环境和源码指纹，提供结果、报告、分析过程及复现包下载。
- 可拒绝：证据不足、公司不唯一、期间冲突、单位不明或工具失败时明确停判。
- 分工清晰：模型负责语言拆解和受限工具请求，本地代码负责数值和规则裁决。
- 事实优先：事实、计算推论和模型解释分别标注，不把解释包装成审计结论。

选题落点

赛题方向	本项目落点	主要输出	当前边界
1 数据结构化提取	质押、中标、股权变动；标签、表格、正文限定句式；可选 OCR	原值、规范值、单位、页码、坐标、缺失与冲突	扫描财务主链和大规模低清复杂表尚未承诺全覆盖
2 财务报告分析	年报、半年报、季报；同比、较上年末变化、累计拆单季	指标表、非经常性损益、扣非增速、利润现金流背离、会计口径线索	缺明细时只给补证框架，不生成未经验证的因果解释
5 研究报告纠错	收入、利润、单位、口径、PE、PB、EV/EBITDA 和引用核查	判定、原因、证据、公式、修改前后片段和未完成项	估值只检查明确输入下的内部一致性，不独立提供行情或投资建议

财务指标抽取是方向 2 的支撑链路。公告事件按独立 Schema 输出，不把年报财务指标冒充公告事件。

系统架构

处理链路为：材料登记 → 文档解析 → 结构与字段抽取 → 证据归一 → 财务与期间计算 → LLM 拆句和受限工具请求 → 本地门控与裁决 → 报告与运行归档。

系统由六个层次组成：

1. 材料层：登记来源、披露时间、文件指纹、报告类型、公司和实际期间。

2. 解析层：读取文字层 PDF，按 words 级坐标恢复表格列、续表表头、单位与标签。

3. 证据层：保存 evidence_id、原文、页码、bbox、文件 SHA、期间、单位和口径。

4. 计算层：使用 Decimal 和显式规则计算同比、差值、占比、倍数和累计拆单季。

5. 智能体层：模型只输出结构化拆句和工具请求，不拥有最终裁决权。

6. 交付层：Web 工作台、CLI、结构化结果、报告、页图、轨迹和复现 ZIP。

核心机制

证据模型

每个关键字段保存材料身份、文件指纹、实际期间、原值、规范值、单位、币种、合并口径、调整状态、页序、印刷页码、bbox 和抽取通道。派生值额外保存全部输入 evidence_id 与计算公式。页序和印刷页码分开记录，避免把 PDF 第几页误写成报告印刷页。

文档与表格抽取

系统使用 words 级坐标恢复表格，而不是按文本行切分。已处理相邻列粘连、跨三行折行标签、续表页不重复年份表头、单位三种写法、百分号与元每股等固有单位。遇到未知版式时宁可标记缺失或待复核，不用其他公司的固定位置硬套。

财务计算与期间门控

累计流量可以先做同期间同比，再进行半年减一季度等合法拆差；EPS、ROE 和期末余额不采用累计拆差。比较前检查期间起止、长度、时点或流量属性、会计政策、合并范围和重述状态。缺少可比依据时保留操作数和尝试值，但不把结果标记为有效。

受限智能体循环

模型接收草稿和证据上下文，输出原子主张、公司、指标、期间、方向及工具请求。工具层只开放证据查询、指标比较、公式计算和文本检索等受控能力。模型返回的每个原子由本地代码再次核对公司、期间、单位和证据方向；冲突时转待复核，不允许模型修改程序裁决。

纠错与评分

核查结果分为证据支持、确认错误、需补证、需复核和执行失败。确认错误以“错误句”为正类统计 TP、FP、TN、FN，同时报告正确覆盖率、精确率、召回率和误报率。漏拆、缺证、超时和程序失败单独统计，不混入已判定正确率。

可复现与运行记录

每次运行保存模型名称、接口模式、参数、依赖版本、源码指纹、文件访问、工具输入输出、计算结果和终态。工作台支持运行切换、SSE 实时进度、断点恢复、长轨迹加载，以及 result.json、report.md、explanation.json 和 reproduction.zip 下载。复现包不包含访问本机会话的 Cookie 或密钥。

当前实现与验证

项目保留 14 家公司、2021 至 2025 年共 70 份巨潮年报的数据底板。历史长表共 710 行，其中 699 行取自当年年报的本年列；9 个核心财务指标达到 70 份材料全覆盖。每个数字保存页码和命中标签，与东方财富历史数据对账 650 项，其中 573 项一致，其余主要为历史重述或第三方口径差异；第三方数据只作交叉验证。

当前固定业务回归覆盖九份年报、两份真实期间报告和两份真实公告，另有三类模拟公告及扫描样例。2026-10-18 将 P0-P4 汇入 `main` 后执行最终完整 Python 回归：517 项通过、1 项跳过、0 失败、0 错误，耗时 48.110 秒；跳过项为 Windows 符号链接权限。HTML、接口、安全与 P4 现场入口测试均在同一轮执行。

批次	最终本地验收证据	当前边界
P0 留出集 v2	2 家公司、4 份材料、30 条陈述，三重泄漏检查为 0；离线回放 28/30（93.33%），真实 `deepseek-chat` 29/30（96.67%），三轮一致率 100%	固定留出集，不是独立盲测；无独立人工复核
P1 解析停判	25 条对抗样例中，静默错绑 0、非唯一解析缺下一步动作 0	未发起新一轮真实模型调用
P2 抽取与 OCR	自动抽取 20/20；扫描页 5/5 可解释转复核，策略违规 0；OCR 不计自动准确率	扫描页由已见页栅格化，不是真实盲测
P3 稳定性	离线故障矩阵 8/8；真实长文档 120 句连续 3 轮、每轮 6 块完成，跨轮签名一致率 1.0，18 次真实请求、127986 Token	未触发真实 429/超时，不能替代业务准确率

P4 现场可运行性	一键自检 READY；8 条样例覆盖 4/2/1/1，6 份 PDF；CLI 35 条证据、失败 0；Web 三入口 200	未验证干净机器、真实供应商故障页面和真人视觉

最终提交代码以标签 `submission-20261018-final` 指向的合并提交为准。P0-P4 各自验收文档、运行摘要与原始结果均保留在 `docs/决赛/` 与 `results/`。

工作台已支持财报分析与研报核查、公告字段抽取、证据页图、运行轨迹、受限追问、完整结果保存和复现包导出。本地启动检查返回 HTTP 200。队友验收记录另包含 466 项通过、2 项跳过的 Windows 合并回归结果，与本次全量回归口径一致。

项目保留真实模型全链路接口和历史 DeepSeek 实测记录。模型名称、接口模式、调用参数与用量写入每次运行记录，密钥只从进程环境读取，不进入源码、报告、视频或 Git。

2026-10-17 对 DeepSeek `deepseek-chat` 完成三次同配置实时评测：三次均完成原生工具调用，应判主张 8/8、漏拆 0、失败 0。对保存的原始输出按修正后的字段评分口径复算，字段完全一致分别为 11/12、12/12、11/12，额外预测为 0；修正后再次实跑一轮得到 12/12。该结果用于证明真实链路、评分一致性与失败可追溯，不作为独立盲测准确率。

与赛题评价维度的对应

评价维度	本项目证据
任务完成度	三条方向均提供可运行入口和结构化输出，不只输出聊天记录
数据与计算准确性	Decimal 复算、期间门控、单位规则、真实材料固定值回归和逐字段对账
分析逻辑严密性	事实、推论和观点分层；缺明细时只给补证框架，不编造原因
证据支撑充分性	文件 SHA、页序、印刷页、bbox、原文和 evidence_id 联合定位
结果稳定性	受限工具、运行状态机、SSE 重放、缓存指纹、断点恢复和失败保留
方案创新性	模型拆句与本地裁决分离，程序规则锁定数字和口径，完整过程可回放
实际应用价值	面向研报复核、公告抽取和财报分析，支持批量留痕与复现审计

数据与评测计划

当前受控错误注入和固定答案回归证明的是确定性规则与工程链路，不等同于任意研报的独立准确率。下一阶段将建立分层评测集：

- 开发集：固定真实材料与历史错误注入，用于回归和定位。
- 留出集：未参与开发的真实研报、公告和报告版式，用于泛化测试。
- 固定答案复核：现有 24 条已完成 AI 辅助原文复核并由项目采用；未进行独立人工复签。
- 独立盲测集（后续）：由未直接参与规则设计的人员确认答案和证据，尚未完成。
- 稳定性测试：相同输入重复运行，检查结构一致、数值一致和证据定位一致。
- 基线对照：与通用模型直接阅读、人工复核和本地规则系统分别比较。

评测报告将分别给出判定准确率、错误召回率、误报率、正确覆盖率、引用支持率、失败率和平均耗时，并公开样本量、材料来源和适用范围。

安全、合规与第三方

系统默认在本地或受控环境运行。上传文件限制数量与大小，接口执行来源检查、限流、安全头和敏感信息脱敏。模型凭证只从环境变量读取，日志不保存密钥。

第三方依赖、模型、数据和代码集中登记名称、版本、来源、许可证和使用范围。公开披露 PDF 不默认视为可自由再分发材料；演示和复现包按实际许可控制材料分发。PyMuPDF 使用 AGPL-3.0 或商业许可，OCR 语言数据使用 Apache-2.0，最终交付将保留完整清单。

团队分工

团队为北京林业大学信息学院 3 人小队，指导教师已确定，最终成员和报名信息以竞赛平台为准。

- 产品与金融验证：定义场景、整理材料和金标、复核财务口径、维护边界与风险清单。
- 智能体与后端：文档抽取、财务计算、工具循环、运行状态、日志、安全和评测。
- 前端与交付：工作台、证据展示、复现包、测试、视频、文档和现场演示。

开发采用小步提交和固定回归。每批先写验收条件，再实现和反向验证；旧入口在新契约通过前保留。提交版本、测试记录和演示版本保持同一 Git 提交。

实施安排

2026-10-18 前完成初赛项目计划书和不超过 5 分钟的项目介绍视频，重点展示真实材料、结构化输出、证据定位、执行轨迹和复现能力。

2026-11 月中旬前完成独立评测集、未见公司与未见版式测试、复杂语义与会计事件、附注与字段扩展、干净环境复现和现场样例准备。初赛提交只采用 `submission-20261018-final` 标签对应代码，不把留出集结果表述为独立盲测准确率。

2026-11 月底决赛前完成最终报告、Web 原型、完整源代码与运行说明、现场实时处理流程、答辩材料和稳定性压测。

风险与处理

风险	处理方式
未见版式导致字段漏抽	明确标记缺失，转入复核；扩测新公司和报告类型，不按固定坐标猜测
模型输出不稳定	拆分原子主张，本地重核对，工具调用限额，失败保留并支持恢复
OCR 或表格质量不足	保存识别依据和原文页图，相关字段统一标记待人工复核
会计政策或重述变化	比较前检查口径和版本，未知时阻断计算，不以旧值补齐
估值或投资判断越界	只检查明确输入下的内部一致性，展示假设、时点和适用范围
第三方材料许可不清	不默认公开再分发，集中登记并限制复现包中的材料范围